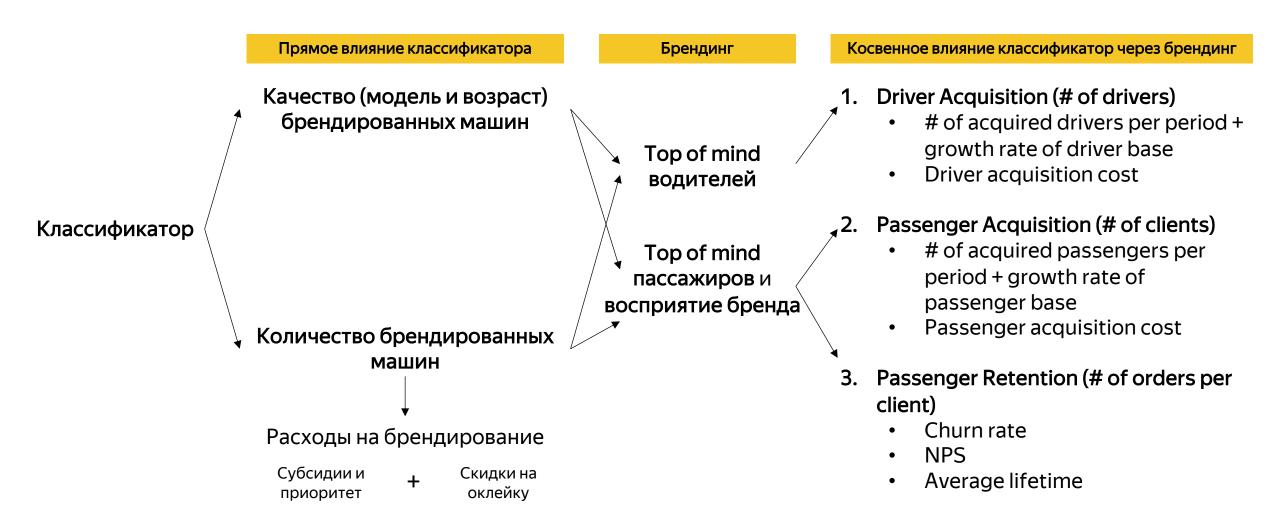


# Классификатор брендирования Яндекс. GO

Алексей Сек

**Часть 1:** Понять для чего использовать классификатор

### Классификатор определяет количество брендированных авто и создает ассоциации Yandex.GO с высоким качеством авто, влияя на привлечение и удержание пассажиров и водителей



### Цель оптимизации классификатора – повышение качества\* брендированных автомобилей при сохранении их количества

#### Определение задачи

Кажется, что существует trade-off между количеством и качеством брендированных авто:

Более мягкий классификатор повысит количество машин, но снизит их качество (более строгий – наоборот)

HO если классификатор был основан HE на данных, а на мнении, его можно оптимизировать, trade-off нет:

Можно повысить одну метрику (количество или качество брендированных авто), не ухудшая второй

Что в свою очередь как минимум не ухудшит все пассажирские и водительские метрики

Повысить количество, сохранив качество брендированных авто

**Можем нарушить бюджетные ограничения:** Большее количество брендированных авто повысит издержки

Поэтому откажемся от решения этой задачи, т.к. нет точных данных об издержках и о бюджетных ограничениях **Повысить качество, сохранив количество** брендированных авто

Решив эту задачу мы точно улучшим классификатор (т.е. улучшим его), при этом не нарушив бюджетные ограничения

Поэтому решим эту задачу

<sup>\*</sup> Качество оценивается на основе обратной связи от пассажиров

# Часть 2: Проанализировать данные

### Сгенерируем индекс плохих поездок, построим новый классификатор на его основе, сравним новый классификатор со старым, оценим влияние на партнеров

1

### Проверка данных и генерация новых признаков

Проверить данные на ошибки и адекватность

Сгенерировать дополнительные метрики

Построить индекс плохих поездок на основе полученных метрик

2

### Построение нового классификатора и его проверка

Построить новый классификатор на основе ранжирования по индексу плохих поездок

Проверить, насколько новый классификатор коррелирует с индексом плохих поездок и сравнить с исходным 3

### Оценка внедрения нового классификатора на партнеров

Оценить распределение изменения в количестве брендированных машин по партнерам (изменения в долгосрочном доходе)

Оценить распределение количества машин, которые нужно обклеить или расклеить по партнерам (изменения в краткосрочном доходе)

## Показатель Bad Model Index, сгенерированный на основе данных по поездкам, позволяет ранжировать модели и годы выпуска авто по предпочтениям пассажиров

#### **Bad Model Index\***

Агрегированный показатель того, насколько конкретная модель и конкретный год выпуска авто этой модели НЕ нравится пассажирам Важно, что он учитывает только те факторы, на которые влияет именно модель и возраст авто и не учитывает факторы, на которые влияет водитель

=

Доля поездок, получивших рейтинг ниже 5 с тегом «не доволен моделью машины» (мы будем смотреть долю такого тега среди всех оцененных поездок, т.к. у нас нет данных по поездкам с рейтингом ниже 5):

disappointed model rate = dissapointed car model tag cnt / trips rated cnt



Доля поездок, отмененных с тегом «не доволен моделью машины»: bad car model rate cancel = bad car model tag cnt / trips cancel cnt

<sup>\*</sup> Можно было бы применить standard scaler к слагаемым индекса, но т.к. размерности одинаковые и значения тоже близкие – я решил просуммировать слагаемые без их стандартизации

# Построим новый классификатор на основе ранжирования по индексу плохих поездок, при этом количество брендированных авто должно остаться таким же, как в исходном классификаторе

#### Основная идея

Предположим, что индекс хорошо описывает предпочтения пользователя

Тогда нам нужно просто проранжировать все строки (модель-год) по индексу

А затем отсечь модели таким образом, чтобы количество авто, которые могут быть брендированы (и следовательно, количество\* брендированных авто) осталось таким же, как при исходном классификаторе

Технически реализовано циклом

Коэффициенты корреляции классификаторов с индексом плохих поездок (который описывает предпочтения пользователей):

Исходный классификатор: -10.5%

Новый классификатор: -45.7%

#### Выводы:

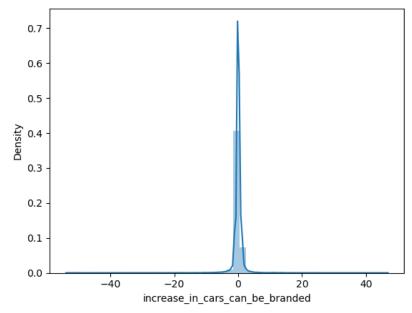
Как можем заметить, новый data-driven классификатор гораздо лучше описывает предпочтения пользователей (модуль коэффициента корреляции выше), чем исходный классификатор, основанный на экспертном мнении сотрудников

<sup>\*</sup> На основе предположения о том, что доля брендированных авто среди авто, которые можно брендировать, останется таким же, как при предыдущем классификаторе

# Оптимизация классификатора почти не изменит долгосрочные доходы большинства партнеров, т.к. количество авто в бренде почти не изменилось. Краткосрочные доходы снизятся несущественно для некоторых партнеров из-за дополнительных расходов на расклейку и оклейку авто

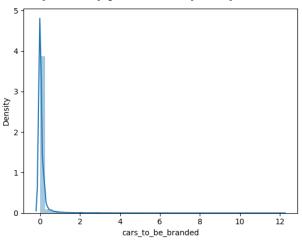
Влияние на доходы партнеров

Распределение того, на сколько изменилось количество авто, которое таксопарки может забрендировать



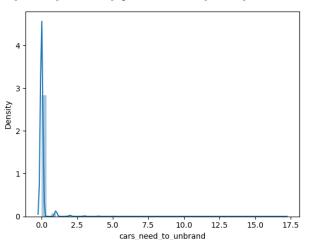
Количество авто, которые партнер может забрендировать почти не изменилось для большинства партнеров -> долгосрочные доходы практически не изменятся

Распределение того, сколько авто таксопарки забрендируют, которые раньше не подходили



Количество авто, которые партнер будет брендировать около 0-2 для большинства партнеров, что не влечет существенных дополнительных издержек -> краткосрочные доходы снизятся несущественно

Распределение того, сколько авто таксопарки разбрендируют, которые раньше подходили



Количество авто, которые партнер будет разбрендировать около 0-2 для большинства партнеров, что не влечет существенных дополнительных издержек -> краткосрочные доходы снизятся несущественно

### Пассажирские и водительские метрики как минимум не ухудшатся, т.к. новый классификатор не снижает количество брендированных авто, но при этом повышает их качество

#### Метрики, на которые классификатор влияет косвенно

- 1. Driver Acquisition (# of drivers)
  - # of acquired drivers per period + growth rate of driver base



Driver acquisition cost



- 2. Passenger Acquisition (# of clients)
  - # of acquired passengers per period + growth rate of passenger base



• Passenger acquisition cost



- 3. Passenger Retention (# of orders per client)
  - Churn rate



NPS



Average lifetime



Влияние на все метрики положительное

### Чтобы поверить в сделанные выводы относительно нового классификатора – необходимо сделать следующие предположения и допущения

#### Предположения:

- Полученный индекс хорошо описывает предпочтения пользователей относительно модели и марки авто. То есть на основе индекса плохих поездок можно делать выводы о том, насколько хорош классификатор
- В среднем по моделям авто все водители одинаковые, все пассажиры тоже одинаковые, то есть при сравнении моделей и годов выпуска авто единственные отличия это и есть модель и год выпуска авто (индивидуальные характеристики пассажиров и водителей не влияют на индекс, который используется в классификаторе, на него влияет только модель и год выпуска авто)
- Доля брендированных авто среди тех, которые можно брендировать, останется такой же при новом классификаторе, какой была при старом классификаторе. То есть все партнеры забрендируют авто, попавшие в новый классификатор, которых не было в старом, при этом разбрендируют авто, не попавшие в новый классификатор, но которые были в старом классификаторе
- Количество брендированных машин яндекса при старом классификаторе оптимальное (т.к. компания старается забронировать максимальное количество машин при условии, что не превысит заданный уровень расходов на брендирование). Таким образом, количество брендированных машин при новом классификаторе будет таким же (оптимальным), как и при исходном классификаторе
- Годы выпуска машин в исходном датасете корректны (например, существует год 0, есть год 30) я предполагаю, что такие нереалистичные годы получились из-за обфусцирования данных

**Часть 3:** Продумать продуктовые сценарии

### Новый классификатор стоит вводить плавно и в период, когда доходы водителей и партнеров стабильны – когда нет других значимых изменений

Оптимальное время – чем раньше, тем лучше, т.к. новый классификатор оптимальнее предыдущего и позитивно должен повлиять на все метрики

При этом стоит подождать, если в этот период внедряют другие инициативы, способные снизить доход водителей и партнеров. Иначе можно получить высокий churn среди партнеров и водителей (и так нужно часть авто оклеивать и расклеивать, а еще и доходы упадут)

1

#### А/В тестирование нового классификатора

Случайно выбираем партнеров в случайных городах и смотрим, как в среднем изменяются:

- 1. Количество брендированных авто
- 2. Доходы партнеров и его водителей
- 3. Количество активных водителей и их churn rate

В сравнении с контрольной группой

Также можно попытаться оценить влияние на пассажирские и водительские метрики, но эффект скорее всего будет с большим лагом и не очень сильный

2

### Определение порядка перевода партнеров на новый классификатор

Нельзя переводить всех партнеров на новый классификатор сразу!

- 1. Станции брендирования могут не справиться с нагрузкой
- 2. Возможен резкий отток большой части активной базы водителей
- 3. Количество автомобилей в брендировании может превысить заложенную в бюджете сумму на скидки по брендированию
- 4. Количество автомобилей в брендировании может превысить заложенную в бюджете сумму на ежемесячные бонусы

3

Непосредственный перевод таксопарков в определенном заранее порядке на новый классификатор

Необходимо следить за теми же показателями, что и при тесте:

- 1. Количество брендированных авто, а следовательно и наши расходы на брендирование
- 2. Доходы партнеров и его водителей
- 3. Количество активных водителей и их churn rate

## Обеспечить соблюдение новых правил можно усиленным контролем (видео и фото фиксация) и суровыми наказаниями (временная блокировка, снижение приоритета, снижение бонусов)



### Appendix: Link to the github

https://github.com/AlexeySek/YD/blob/af5ce29be8a16cd2b42 2d3615ff8c2d2d36c9d9e/YD\_Alexey\_Sek.ipynb